

# СОДЕРЖАНИЕ

|                                                                               |    |
|-------------------------------------------------------------------------------|----|
| Введение.....                                                                 | 2  |
| 1. ИССЛЕДОВАТЕЛЬСКИЙ РАЗДЕЛ.....                                              | 3  |
| 1.1 Предметная область .....                                                  | 3  |
| 1.1.1 Анализ текущего состояния .....                                         | 4  |
| 1.1.2 Выявление основных проблем и ограничений.....                           | 6  |
| 1.2 Обзор существующих решений .....                                          | 9  |
| 1.2.1 Сравнительный анализ существующих решений .....                         | 9  |
| 1.2.2 Выявление недостатков и ограничений аналогов .....                      | 13 |
| 1.3 Постановка задачи на разработку проекта модели .....                      | 15 |
| 1.3.1 Определение целей, задач и критериев успешности .....                   | 15 |
| 1.3.2 Формализация требований к разрабатываемому решению .....                | 17 |
| 1.3.3 Определение ограничений и допущений.....                                | 18 |
| 2 Аналитический раздел .....                                                  | 20 |
| 2.1 Описание модели данных .....                                              | 20 |
| 2.1.1 Описание источников и форм данных .....                                 | 20 |
| 2.1.2 Методы предобработки данных и очистки данных .....                      | 23 |
| 2.1.3 Оценка качества и репрезентативности данных .....                       | 25 |
| 2.2 Описание этапов разработки проекта системы.....                           | 28 |
| 2.2.1 Проектирование архитектуры решения .....                                | 28 |
| 2.2.2 Описание математического аппарата реализуемого решения .....            | 31 |
| 2.2.3 Разработки вычислительной схемы.....                                    | 35 |
| 2.3 Обоснование выбора инструментальных средств разработки системы....        | 37 |
| 2.3.1 Сравнительный анализ и критерии выбора программных инструментов .....   | 37 |
| 2.3.2 Описание выбранной среды разработки и требований к инфраструктуре ..... | 40 |
| Заключение.....                                                               | 43 |
| СПИСОК ИСПОЛЬЗУЕМЫХ ИСТОЧНИКОВ.....                                           | 44 |

|                  |    |
|------------------|----|
| ПРИЛОЖЕНИЕ ..... | 49 |
|------------------|----|

# ВВЕДЕНИЕ

Своевременная и максимально точная диагностика на ранних стадиях является ключевым фактором успеха в лечении злокачественных новообразований. В структуре современной онкопатологии рак легких стабильно удерживает лидирующие позиции как по уровню смертности, так и по сложности своевременного выявления. Огромный объем накопленных клинических данных диктует необходимость внедрения в медицину продвинутых автоматизированных инструментов поддержки принятия врачебных решений. Применение методов интеллектуального анализа данных на основе обширных верифицированных наборов показателей позволяет значительно систематизировать оценку рисков и минимизировать человеческий фактор в первичной диагностике.

Цель работы — обоснование и разработка сервиса для помощи врачам в прогнозировании рисков рака легких.

Для достижения поставленной цели в соответствующих разделах решаются следующие задачи:

1. Исследовательский раздел: глубокое изучение предметной области, проведение детального сравнительного анализа существующих программных решений для диагностики онкозаболеваний и обзор наиболее перспективных современных математических методов прогнозирования.
2. Аналитический раздел: обоснование выбора стека технологий, проектирование функциональной архитектуры приложения, детальное описание структуры базы данных и выбор конкретной алгоритмической базы для реализации аналитического модуля.

Данные этапы станут базой для последующей технической реализации программного продукта.

# **1. ИССЛЕДОВАТЕЛЬСКИЙ РАЗДЕЛ**

## **1.1 Предметная область**

Становление медицинской информатики как самостоятельной научной дисциплины и практического направления началось в середине XX века (1950-е — начало 1960-х годов). На ранних этапах развитие данной области было сфокусировано на математическом моделировании патогенетических механизмов и реализации алгоритмов вычислительной диагностики. Фундаментальным шагом стало появление первых автоматизированных систем ведения историй болезни, которые со временем эволюционировали в современные комплексные системы электронных медицинских карт (ЭМК).

В современной научной парадигме используется термин e-Health (электронное здравоохранение), который охватывает использование информационно-коммуникационных технологий для поддержки всех аспектов охраны здоровья. Электронное здравоохранение включает в себя не только цифровизацию документооборота, но и внедрение систем поддержки принятия врачебных решений (СППВР), телемедицину, отслеживания здоровья населения на основе анализа больших данных (Big Data) и образовательные платформы для специалистов.

Ключевым инструментом трансформации современной медицины в высокотехнологичную отрасль является СППВР. На рисунке 1.1 представлена концептуальная схема функционирования такой системы, демонстрирующая процесс преобразования первичных медицинских данных в прикладные рекомендации для специалиста.



**Рисунок 1.1 — Схема СППВР**

Таким образом в центре внимания настоящего исследования находится процесс взаимодействия врача с массивами медицинских данных пациента.

### **1.1.1 Анализ текущего состояния**

Современная медицина находится на этапе глобальной цифровой трансформации, где ключевым вектором развития становится внедрение систем поддержки принятия врачебных решений (СППВР). Интеграция информационных технологий в клиническую практику направлена на минимизацию человеческого фактора и повышение точности диагностических

мероприятий. Использование алгоритмов интеллектуального анализа данных позволяет не только повысить эффективность систематизации медицинских сведений, но и увеличить объективность процесса постановки диагноза, предсказывать риски осложнений и персонализировать терапевтические схемы. Технологический стек современной клиники сегодня включает в себя облачные технологии для хранения огромных архивов медицинских данных, а специализированные аналитические помогают в отслеживании состояния пациентов.

Особую актуальность данные технологии приобретают в сфере онкологии, в частности при диагностике и прогнозировании рака легких, который остается одной из ведущих причин смертности во всем мире. Раннее выявление новообразований напрямую коррелирует с выживаемостью пациентов, однако визуальный анализ радиологических снимков и интерпретация множества факторов риска требуют от специалиста предельной концентрации и высокой квалификации. Автоматизированные сервисы анализа данных позволяют проводить скрининг на качественно новом уровне, выявляя минимальные аномалии в структуре тканей и сопоставляя их с анамнестическими данными пациента.

Текущая ситуация в клинической практике характеризуется экспоненциальным ростом объемов генерируемой информации. К основным источникам данных относятся:

- структурированные данные лабораторных и биохимических исследований;
- неструктурированные текстовые записи осмотров и истории болезни из электронных медицинских карт;
- данные визуализации высокого разрешения, такие как компьютерная томография (КТ), магнитно-резонансная томография (МРТ) и позитронно-эмиссионная томография (ПЭТ-КТ);

- результаты исследований, полученные в ходе генетического анализа, расшифровки отдельных участков ДНК и специальных тестов на онкомаркеры.

Такой колоссальный поток сведений создает критическую когнитивную нагрузку на медицинский персонал. В условиях жесткого временного регламента, отведенного на прием одного пациента, это неизбежно ведет к возникновению «информационной слепоты», пропускам в динамике заболевания или несвоевременной корректировке тактики лечения. В то же время накопленная избыточность данных при правильном подходе превращается в ценный ресурс.

### **1.1.2 Выявление основных проблем и ограничений**

Проведенный анализ предметной области позволяет выделить комплекс критических проблем и ограничений, препятствующих эффективному внедрению аналитических сервисов в клиническую практику онкологической службы. Данные барьеры классифицируются на методические, технические и специфические (обусловленные биологией заболевания).

Методические проблемы диагностики и прогнозирования. Ключевой проблемой является «проблема скрытого течения» (латентности). Рак легких характеризуется длительным бессимптомным периодом, в течение которого стандартные методы скрининга могут давать ложноотрицательные результаты. Существующие протоколы часто опираются на жалобы пациента, что смещает фокус внимания врача на поздние стадии заболевания (III–IV), когда эффективность терапии резко снижается.

Второй важной методической проблемой является субъективность в интерпретации многофакторных данных. Врач физически не способен одновременно сопоставить в уме более 20–30 переменных, которые могут

влиять на онкологию, например такие как экологических факторы или генетические предрасположенности, чтобы провести оценку кумулятивного риска. Без использования средств автоматизации, расчет риска будет носить персональный оценочный характер, что повышает вероятность ошибки.

Технические и информационные ограничения:

1. Проблема фрагментарности и качества данных (Data Silos). Несмотря на наличие медицинских информационных систем, данные о пациенте часто распределены между различными учреждениями (поликлиники, онкоцентры, диагностические лаборатории). Отсутствие единого семантического стандарта описания социально-демографических факторов (например, уровня загрязнения воздуха в регионе проживания) создает сложности для предиктивного моделирования.
2. Дисбаланс классов в обучающих выборках. В реальной клинической практике количество случаев подтвержденной онкологии значительно меньше числа здоровых пациентов или лиц с доброкачественными образованиями. Это накладывает ограничения на использование простейших алгоритмов машинного обучения, требуя применения специализированных техник балансировки данных и оценки точности через метрики Recall и F1-score, так как цена пропуска цели (false negative) в онкологии критически высока.
3. Проблема «черного ящика» и интерпретируемости. Для врача-онколога недостаточно получить численный прогноз вероятности заболевания. Критически важно понимать, какие именно факторы (например, сочетание стажа курения и контакта с асбестом) внесли решающий вклад в итоговый результат. Недостаточная объяснимость (Explainable AI) современных нейросетевых моделей является серьезным психологическим и юридическим барьером для

их внедрения в контур принятия клинических решений.

Ограничения предметной области (специфика рака легких):

1. Мультифакторная природа. Трудно точно разделить, как на риск болезни влияют гены, а как — внешняя среда (например, радон или смог), поэтому создать универсальную модель прогноза, которая бы одинаково хорошо работала в разных регионах, пока проблематично.
2. Динамичность показателей. Биомаркеры и состояние пациента меняются во времени, что требует не разового анализа, а построения динамических рядов (Time Series Analysis), что существенно усложняет архитектуру аналитического сервиса.

Итогом этого раздела стали выявленные проблемы, которые указывают на то, что проектируемый сервис должен не просто агрегировать данные, а решать задачу извлечения скрытых паттернов в условиях неопределенности и неполноты информации. Таким образом, приоритетной задачей разработки становится создание инструментов интеллектуальной интерпретации данных, которые позволят минимизировать влияние человеческого фактора и обеспечить предиктивную поддержку врача на этапе, предшествующем инструментальной диагностике.

Подводя же резюме по исследуемой предметной области, можно сделать следующий вывод, что она находится на стыке медицины, математической статистики и информационных технологий. Ее развитие направлено на создание надежного инструментария, способного повысить точность предиктивной диагностики и оптимизировать работу врачей, в частности, онкологов в условиях стремительно растущих потоков медицинской информации и развития технологий.

## 1.2 Обзор существующих решений

### 1.2.1 Сравнительный анализ существующих решений

Современные системы поддержки принятия врачебных решений (СППВР), используемые в клинической практике, представляют собой обширный перечень программного обеспечения. Их можно разделить по нескольким факторам, таким как функциональному назначению, автоматизированности и методам обработки данных, на следующие ключевые категории:

- Первая группа включает в себя информационно-справочные системы и цифровые медицинские библиотеки, такие как «Справочник врача», UpToDate или Medscape. Данные платформы выступают в роли агрегаторов колоссальных объемов медицинской информации, предоставляя специалистам доступ к актуальным клиническим рекомендациям, международным протоколам и результатам последних метаанализов. Основное преимущество таких систем заключается в высокой достоверности данных и удобстве навигации по сложным медицинским терминам. Однако существенным недостатком является их пассивный характер: врач должен самостоятельно инициировать поиск, изучить массив данных, провести качественный анализ и лишь затем синтезировать решение. В условиях дефицита времени это может замедлять процесс постановки диагноза.
- Вторая группа объединяет специализированные медицинские калькуляторы, например: MDCalc, Calculate by QxMD или Pedi STAT. Эти инструменты часто рассматриваются как дополнение к

справочникам, но имеют иную функциональную направленность — количественную оценку клинических параметров. Они позволяют оперативно рассчитать дозировку препаратов, индекс массы тела, клиренс креатинина или шкалы риска. Несмотря на практическую значимость, такие приложения обладают узкой специализацией и могут демонстрировать предвзятость в рекомендациях, если алгоритм был разработан при поддержке конкретных фармацевтических брендов.

- Третья группа представлена системами, ориентированными на сбор, централизованное хранение и отслеживание данных пациентов. К ним относятся глобальные решения вроде Watson Health от IBM, Doctolib, а также наиболее масштабный российский пример — ЕМИАС. Основная задача таких платформ — формирование единого цифрового профиля пациента. Системы способны в автоматическом режиме уведомлять врача о критических отклонениях в лабораторных показателях или предупреждать о несовместимости назначенных препаратов. Главным барьером для их развития остается проблема интероперабельности: данные зачастую заблокированы внутри одной экосистемы или лечебного учреждения, что затрудняет бесшовную передачу информации между разными медицинскими организациями.
- Четвёртая группа базируется на применении технологий искусственного интеллекта и нейронных сетей. В эту категорию входят такие продукты, как Ada Health, SberMedAI или специализированные модули анализа флюорограмм от ООО «ФтизисБиоМед». Спектр их применения крайне широк: от предиктивной аналитики на основе анамнеза до высокоточной

расшифровки графических данных, таких как рентген, КТ или МРТ. Несмотря на потенциальную способность минимизировать человеческий фактор, данные системы сталкиваются с проблемой «черного ящика» — отсутствием прозрачности в принятии решений, а также испытывают трудности при обработке редких клинических случаев. Кроме того, использование таких систем ограничено юридическими коллизиями, связанными с ответственностью за ошибочный автоматизированный диагноз.

В узкоспециализированном сегменте онкологии и диагностики рака легких выделяются следующие ключевые решения:

1. ONCOTODAY — мобильное и десктопное справочно-прикладное приложение созданное британской благотворительной организацией Together Against Cancer Fund. Аккумулирует базу знаний, протоколы ведения пациентов и инструменты верификации лечения.
2. Watson for Oncology от компании IBM — система на базе алгоритмов машинного обучения для анализа электронных медицинских карт и научных публикаций с целью формирования персонализированных вариантов терапии.
3. Разработки Google Health — алгоритмы глубокого обучения и нейронные сети, демонстрирующие прецизионную точность при сегментации и классификации образований на КТ-снимках легких.
4. «Цельс» или Celsus — российская интеллектуальная платформа для анализа цифровых изображений, автоматизирующая процесс просмотра рентгенограмм и КТ-исследований.
5. Botkin.AI от компании ООО «Интеллоджик» — облачное решение для автоматизированного анализа результатов КТ, МРТ и рентгена, использующее ИИ для построения трехмерных карт поражений.
6. «Онконет» производства ООО «Телепат» — сервис дистанционного

контроля и телемедицинского взаимодействия, обеспечивающий сбор данных о состоянии пациента в динамике.

На основе проведенного обзора сформирована классификация профильных систем по четырем функциональным категориям:

1. Визуализационные системы. Данные программы направлены на анализ графических данных, таких как КТ/Рентген.
2. Рекомендательные системы. Эти же приложения используются для подбора терапии для уже выявленных случаев.
3. Аналитические/Предиктивные системы. Они используются для оценки вероятности заболевания и помощь в постановке первичного диагноза.
4. Мониторинговые системы. Данные системы предназначены для контроля состояния и сбора статистических данных.

Для детального сопоставления характеристик исследуемых решений в таблице 1.1 приведен сравнительный анализ общих групп медицинских приложений.

*Таблица 1.1 – Сравнение групп медицинских приложений*

| Группа приложений                | Назначение                            | Сильные стороны                                                 | Слабые стороны                                                          |
|----------------------------------|---------------------------------------|-----------------------------------------------------------------|-------------------------------------------------------------------------|
| Информационно-справочные системы | Предоставление актуальных мед. данных | Высокая достоверность, фундаментальность информации             | Пассивность, требуют значительных временных затрат врача                |
| Медицинские калькуляторы         | Расчет дозировок и рисков по формулам | Высокая скорость вычислений, автоматизация расчетов             | Узкая специализация, возможная предвзятость алгоритмов                  |
| Системы сбора данных             | Ведение цифровых карт пациентов       | Актуальность анамнеза, автоматические уведомления               | Сложность интеграции между разными системами (интероперабельность)      |
| Системы на базе нейросетей       | Поиск паттернов в данных и снимках    | Высокая точность диагностики, скорость обработки больших данных | Проблема интерпретируемости, юридические риски, ошибки в редких случаях |

Таким образом, выявленный дефицит доступных сервисов для комплексного анализа факторов риска и предиктивного моделирования подтверждает необходимость разработки специализированного решения. Создание аналитической системы на базе профильных наборов данных позволит заполнить пустующую нишу инструментов поддержки принятия решений и обеспечить эффективный скрининг групп риска. Обоснованная актуальность проекта требует перехода к детальному рассмотрению методологии и архитектуры проектируемого сервиса в следующей главе.

### 1.2.2 Выявление недостатков и ограничений аналогов

Детальный критический анализ существующих решений позволяет выявить ряд существенных ограничений, препятствующих их повсеместному и эффективному внедрению в практику первичного звена здравоохранения.

Для оценки рыночного ландшафта в контексте выбранной темы ВКР составлена сравнительная таблица 1.2, описывающая недостатки конкретных программных продуктов.

*Таблица 1.2 – Сравнение медицинских приложений для онкологов*

| Программный продукт | Тип системы                | Ключевые преимущества                                   | Основные недостатки                                                         |
|---------------------|----------------------------|---------------------------------------------------------|-----------------------------------------------------------------------------|
| ONCOTODAY           | Справочная, Мониторинговая | Наличие профессиональных калькуляторов и протоколов     | Отсутствие автоматизированного анализа данных пациента                      |
| Watson for Oncology | Рекомендательная (ИИ)      | Глубокий анализ научной литературы, обоснование лечения | Высокая стоимость, зависимость от западных протоколов                       |
| Google Health AI    | Визуализационная           | Сверхточный поиск патологий на КТ-снимках               | Игнорирование неструктурированных факторов риска, представленных в анамнезе |

Продолжение Таблицы 1.2

|                  |                      |                                                     |                                                           |
|------------------|----------------------|-----------------------------------------------------|-----------------------------------------------------------|
| Celsus или Цельс | Визуализационная     | Эффективность при массовых скринингах легких        | Фокус только на снимках, отсутствие предиктивного анализа |
| Botkin.AI        | Диагностическая (ИИ) | Минимизация врачебных ошибок при пропуске очагов    | Регуляторные риски, нестабильность точности диагнозов     |
| Онконет          | Телемедицинская      | Эффективный сбор статистики, отслеживания состояния | Не предназначена для оценки рисков и постановки диагноза  |

Главным недостатком информационно-справочных систем, наподобие UpToDate или ONCOTODAY, будет их пассивный характер: врач при работе с ними должен самостоятельно инициировать поиск информации, и уже на основе неё создать решение, что в условиях дефицита времени замедляет постановку диагноза. Медицинские калькуляторы, несмотря на их высокую практическую пользу, обладают также важным неудобством, они крайне узко специализированы, а также могут иметь риск предвзятости алгоритмов.

Для масштабных платформ сбора данных, таких как ЕМИАС или Watson Health, главным барьером остается проблема интероперабельности — данные зачастую заблокированы внутри одной экосистемы, что затрудняет бесшовную передачу информации. А системы на базе ИИ, в большей степени сосредоточенны на работе с визуальными данными, или имеют сложности с законодательством.

В сегменте онкологии выделяются следующие критические ограничения:

1. Технологическая специализация: решения от Google Health и «Цельс» сфокусированы в основном на визуализации. Вне зоны ответственности их алгоритмов остаются комплексные факторы риска, такие как образ жизни, генетика и экология.
2. Экономические и адаптационные барьеры: Watson for Oncology характеризуется крайне высокой стоимостью лицензирования и

ориентацией на западные стандарты, вступающие в противоречие с локальными рекомендациями РФ.

3. Регуляторные и операционные риски: на примере Botkin.AI зафиксированы сложности в сертификации и стабильности работы, например приостановка эксплуатации Росздравнадзором в 2023 году, а также риски ложноположительных результатов.
4. Ограниченность функционала: сервисы мониторинга, такие как Онконет, не решают задачу предиктивной аналитики на этапе раннего выявления заболевания.

Таким образом, анализ показал, что рынок насыщен либо узкоспециализированными инструментами визуализации, либо пассивными справочниками. Практически отсутствуют доступные аналитические сервисы, комплексно сочетающие анализ неструктурированных данных (факторы риска, образ жизни) с предиктивным моделированием вероятности рака легких. Выявленные недостатки подтверждают актуальность разработки аналитического сервиса на базе набора данных «Lung Cancer Risk & Prediction Dataset», который должен занять нишу доступной системы поддержки принятия решений для раннего выявления групп риска.

## **1.3 Постановка задачи на разработку проекта модели**

### **1.3.1 Определение целей, задач и критериев успешности**

На основе ранее проведенного анализа предметной области и детального обзора существующих программных продуктов было установлено, что современные ИТ-решения в онкологии тяготеют либо к сложной визуальной диагностике, например, автоматизированному анализу КТ или МРТ-снимков,

либо к пассивным информационным справочно-рекомендательным системам. Несмотря на существенный технологический прогресс, на рынке медицинских технологий наблюдается дефицит доступных и легковесных аналитических сервисов, предназначенных непосредственно для первичного звена здравоохранения — терапевтов и пульмонологов. Именно эти специалисты первыми контактируют с пациентом, однако в условиях жесткого временного регламента приема они не всегда имеют возможность вручную сопоставить десятки разрозненных факторов риска для качественного выделения групп высокой вероятности развития заболевания.

Следовательно, основной целью данной работы является разработка программного аналитического сервиса для поддержки принятия врачебных решений (СППВР), который позволит проводить первичную автоматизированную сегментацию пациентов по уровням риска развития рака легких на основе комплекса клинико-anamнестических данных.

Для достижения поставленной цели предстоит решить следующий продуманный комплекс задач, который включает ключевые этапы разработки системы. Этот комплекс состоит из следующих шагов:

1. Формирование и предобработка признакового пространства, основанного на структурированных данных о пациентах. На этом этапе будет собрана и очищена информация о пациентах, с целью создания качественного набора признаков для анализа.
2. Разработка, обучение и валидация предиктивной модели с использованием алгоритмов классификации. Этот этап заключается в подборе и настройке подходящих моделей машинного обучения, их обучении на размеченных данных, а также проверке результата.
3. Проектирование модуля визуализации и графической интерпретации результатов. Данный модуль позволит наглядно представить работу алгоритмов и визуально отобразить исходные данные, что повысит прозрачность и интерпретируемость.

4. Создание интегрированного информационно-справочного модуля, предназначенного для поддержки верификации прогнозов. Он будет включать базу знаний с рекомендациями и ссылками на клинические протоколы.
5. Проектирование и реализация пользовательского интерфейса, специально адаптированного под нужды врачей первичного звена. Интерфейс обеспечит простоту ввода данных, быстрый доступ к прогнозам и интуитивное взаимодействие, минимизируя нагрузку.

Критерием успешности разработки является создание работоспособного прототипа, обеспечивающего высокую точность сегментации. Особое внимание в процессе оценки качества модели должно быть уделено метрикам полноты и F1-score. В задачах первичного онкологического скрининга цена «пропуска цели» критически высока, поэтому максимизация Recall при сохранении приемлемого уровня точности является приоритетным техническим критерием.

Сформулированные цели и задачи определяют вектор технической реализации проекта, однако для их практического воплощения требуется детальная декомпозиция функциональных и информационных составляющих системы.

### **1.3.2 Формализация требований к разрабатываемому решению**

Для обеспечения высокого качества работы аналитического сервиса необходимо зафиксировать требования к его функциональным модулям и информационному обеспечению. Исходными данными для модели должны служить многофакторные показатели, характеризующие состояние здоровья и анамнез пациента. Входные параметры (признаковое пространство) должны включать в себя:

- социально-демографические характеристики;
- факторы образа жизни и негативного влияния окружающей среды;
- профессиональные вредности и генетическую предрасположенность;
- текущие клинические симптомы и жалобы пациента.

Важным требованием к системе является внедрение инструментов графического представления данных, обеспечивающих высокую когнитивную доступность и наглядность. Визуализация должна обеспечивать удобство работы специалисту с данными.

Информационно-справочный блок-системы должен выполнять функции «единого окна знаний». Необходимо интегрировать справочник, содержащий актуальную информацию о симптоматике, стадиях заболевания и выдержки из базовых клинических рекомендаций. Это позволит врачу не только получить расчетный риск, но и оперативно верифицировать полученный прогноз в соответствии с медицинскими протоколами. С точки зрения пользовательского взаимодействия, система должна отличаться минималистичным дизайном и быстродействием, что является критическим требованием для интеграции в плотный график амбулаторного приема.

Детальное описание требований позволяет определить рамки функционала приложения, однако эффективная реализация невозможна без учета внешних факторов и технологических границ проекта.

### **1.3.3 Определение ограничений и допущений**

Разработка аналитического сервиса ведется с учетом ряда технологических и предметных ограничений. Объектом разработки является программный аналитический сервис, а предметом — методы и алгоритмы

машинного обучения для оценки рисков возникновения рака легких.

К основным ограничениям проекта относятся:

1. Тип входных данных. Модель ориентирована на работу со структурированными клинико-анамнестическими данными. Обработка неструктурированных медицинских текстов или сырых DICOM-файлов в рамках данной итерации разработки не предусматривается.
2. Область применения. Сервис позиционируется как инструмент поддержки принятия решений (СППВР) для врачей первичного звена и не является самостоятельным средством постановки окончательного диагноза. Итоговый продукт призван стать связующим звеном между первичным сбором анамнеза и направлением на углубленную инструментальную диагностику.
3. Технологический стек. Система должна быть легковесной, что накладывает ограничения на использование ресурсоемких нейросетевых архитектур в пользу более производительных и интерпретируемых алгоритмов классификации, способных работать на стандартном офисном оборудовании медицинских организаций.

В качестве основного допущения принимается тот факт, что данные, вводимые специалистом в систему, являются достоверными и полными в границах доступного медицинского обследования. Предполагается, что выявление вероятности рака являются достаточными для принятия решения о дальнейшей маршрутизации пациента.

Учет вышеуказанных ограничений и требований позволяет сформировать целостное видение проекта, что создает необходимую базу для перехода к аналитическому обоснованию выбора конкретных методов реализации в последующих разделах.

## **2 АНАЛИТИЧЕСКИЙ РАЗДЕЛ**

### **2.1 Описание модели данных**

#### **2.1.1 Описание источников и форм данных**

Работа разрабатываемой системы строится на анализе накопленной статистики, которую можно собрать из самых разных источников: медицинских информационных систем, государственных реестров и баз данных о заболеваемости раком легких. Информационной основой исследования стали структурированные данные, представленные в виде таблиц.

Для обучения и проверки работы алгоритмов был выбран специальный датасет с подробной информацией о пациентах. Такой табличный формат очень удобен, так как позволяет эффективно использовать методы машинного обучения для поиска связей между факторами риска и прогнозом болезни. Данные взяты из открытого источника Kaggle под названием «Lung Cancer Risk & Prediction Dataset».

Ниже приведен перечень параметров (столбцов) используемого набора данных с кратким описанием каждого показателя:

- Country — страна проживания пациента для учета региональной специфики и качества среды;
- Age — возраст пациента (в диапазоне от 30 до 90 лет), являющийся одним из ключевых факторов риска;
- Gender — пол пациента (мужской или женский);
- Smoking\_Status — текущий статус курения (курильщик, некурящий,

бывший курильщик);

- Second\_Hand\_Smoke — наличие фактора пассивного курения в окружении пациента;
- Air\_Pollution\_Exposure — уровень воздействия загрязненного атмосферного воздуха (низкий, средний, высокий);
- Occupation\_Exposure — наличие вредных производственных факторов на месте работы;
- Rural\_or\_Urban — тип местности проживания (сельская или городская среда);
- Socioeconomic\_Status — социально-экономический статус пациента, влияющий на образ жизни;
- Healthcare\_Access — уровень доступности медицинской помощи (хороший, ограниченный, плохой). Оценивается на основе сложности получения медицинской помощи и её качестве;
- Insurance\_Coverage — наличие медицинской страховки у пациента;
- Screening\_Availability — доступность программ диспансеризации и профилактических осмотров;
- Stage\_at\_Diagnosis — стадия заболевания, зафиксированная на момент постановки диагноза (от I до IV);
- Cancer\_Type — гистологический тип рака (мелкоклеточный или немелкоклеточный);
- Mutation\_Type — выявленный тип генетической мутации (EGFR, ALK, KRAS или их отсутствие);
- Treatment\_Access — возможность получения необходимого лечения в полном или частичном объеме;
- Clinical\_Trial\_Access — информация об участии пациента в клинических испытаниях новых препаратов;
- Language\_Barrier — наличие языкового барьера, затрудняющего

коммуникацию с врачом;

- `Mortality_Risk` — расчетная вероятность летального исхода в диапазоне от 0.0 до 1.0;
- `5_Year_Survival_Probability` — статистическая вероятность выживаемости в течение пяти лет;
- `Delay_in_Diagnosis` — зафиксированные задержки в процессе постановки диагноза;
- `Family_History` — наличие случаев онкологических заболеваний в семейном анамнезе;
- `Indoor_Smoke_Exposure` — воздействие дыма внутри жилых или рабочих помещений;
- `Tobacco_Marketing_Exposure` — степень подверженности влиянию рекламы табачной продукции;
- `Final_Prediction` — целевой признак, определяющий наличие или отсутствие рака легких в финальном прогнозе.

Представленный перечень признаков формирует детальный цифровой профиль пациента, объединяющий биологические маркеры, клинические показатели и социально-средовые факторы риска. Столь многогранная информационная база закладывает основу для создания предиктивной модели, способной учитывать не только медицинские показатели, но и внешние детерминанты здоровья. Комплексный характер данных позволяет перейти к формированию алгоритмов поддержки принятия врачебных решений, однако их возможная разнородность и наличие специфических расчетных величин требуют предварительной подготовки. В связи с этим следующим этапом работы станет выполнение процедур, необходимых для обеспечения качества и консистентности входной информации, что будет подробно рассмотрено в следующей главе

## 2.1.2 Методы предобработки данных и очистки данных

После завершения этапа сбора необходимых массивов данных критически важным шагом становится их технологическая подготовка к последующему анализу и построению прогностических моделей. Эффективность и точность работы алгоритмов машинного обучения напрямую детерминированы качеством входной информации. В контексте разработки сервиса для прогнозирования риска развития рака легких медицинские данные зачастую характеризуются высокой степенью неоднородности, наличием значительного количества пропусков и специфическими форматами клинических записей.

Процесс предобработки представляет собой фундаментальный этап исследования, поскольку большинство алгоритмов чувствительны к статистическому шуму и несоответствию типов переменных. В рамках данной работы для подготовки набора данных «Lung Cancer Risk & Prediction Dataset» был реализован комплекс специализированных методов очистки и трансформации:

1. Идентификация и устранение дубликатов. Первоочередной задачей является выявление и удаление повторяющихся записей. Наличие избыточных данных может привести к эффекту переобучения модели, при котором алгоритм придает необоснованно высокий вес одним и тем же клиническим случаям, что искажает итоговую прогностическую способность. Проверка на дублирование осуществлялась путем сопоставления совокупности всех признаков в каждой записи.
2. Верификация данных и поиск аномальных значений. На данном этапе проводился контроль логической непротиворечивости и допустимости значений. Анализ включал проверку вхождения

данных в установленные медицинские нормы и выявление статистических выбросов, которые могут возникнуть вследствие ошибок при вводе или сбоев в работе информационных систем.

3. Нормализация форматов и преобразование типов. Данный шаг направлен на приведение всех структурных элементов датасета к единому стандарту. Унификация форматов записи и контроль типов данных обеспечивают корректное считывание информации программными библиотеками.
4. Кодирование категориальных признаков. Поскольку большинство математических методов и алгоритмов оптимизированы для работы исключительно с числовыми векторами, качественные характеристики, такие как пол, наличие специфических симптомов или сопутствующие заболевания, были преобразованы в репрезентативные числовые формы посредством методов кодирования.
5. Масштабирование признаков. Заключительный этап предполагает приведение всех числовых характеристик к единому диапазону значений. Это особенно актуально для клинических показателей, имеющих разный физический смысл и разную размерность, так как значительные различия в масштабах могут привести к доминированию одних признаков над другими в процессе обучения модели.

Реализованный комплекс мер по предобработке позволил трансформировать разрозненные сведения в структурированный набор данных, пригодный для машинного обучения. Однако для подтверждения надежности будущих прогнозов недостаточно лишь технической чистоты данных — необходимо удостовериться в их статистической достоверности. Это обуславливает переход к оценке качества и репрезентативности выборки, в ходе которой будет определено, насколько полно и точно подготовленный

массив данных отражает реальную клиническую картину и целевую популяцию пациентов.

### **2.1.3 Оценка качества и репрезентативности данных**

После завершения технического этапа очистки и предобработки данных критически важным шагом является проведение глубокого анализа подготовленного массива на предмет его качества и репрезентативности. В машинном обучении и медицинской аналитике под репрезентативностью понимается способность выборки адекватно отражать свойства всей генеральной совокупности пациентов. Если данные будут смещены или содержать скрытые закономерности, не характерные для реальной клинической практики, итоговая предиктивная модель сервиса не сможет обеспечить требуемую точность прогноза, что в онкологии недопустимо ввиду высокой цены ошибки.

Одним из наиболее значимых аспектов оценки качества в контексте данной работы является анализ сбалансированности классов. Под «классами» подразумеваются целевые уровни риска развития заболевания или наличие конкретных типов патологий. В медицинских датасетах, связанных с онкологией, часто наблюдается значительный перекос в сторону здоровых пациентов, в то время как случаи подтвержденного заболевания составляют лишь малую долю. Такой дисбаланс критичен: алгоритмы классификации имеют тенденцию обучаться на мажоритарном классе, что приводит к высокой общей точности, но крайне низкой полноте по целевому классу. В проектируемом сервисе наиболее важным является именно минимизация ложноотрицательных результатов, поэтому анализ распределения целевой переменной необходим для выбора дальнейшей стратегии обучения: применения весовых коэффициентов или методов синтетической генерации

примеров меньшего класса.

Помимо баланса классов, оценка качества данных включает в себя анализ полноты и связности признакового пространства. На данном этапе исследуется, насколько полно представлены основные факторы риска — такие как стаж табакокурения, экологические показатели, а также генетические маркеры. Оценка репрезентативности в данном случае заключается в проверке того, охватывает ли массив данных различные демографические группы и географические условия проживания. Наличие широкого спектра факторов риска позволяет говорить о высокой прогностической ценности выборки, так как развитие рака легких — это мультифакторный процесс, зависящий от кумулятивного воздействия среды и наследственности.

Важным инструментом верификации качества исследования также является визуализация данных. Графический анализ позволяет выявить скрытые закономерности, которые сложно заметить при простом просмотре таблиц. Для оценки подготовленного набора данных были использованы следующие типы визуализаций:

1. Гистограммы распределения ключевых факторов. Они позволили наглядно оценить плотность данных по возрасту пациентов и интенсивности факторов влияния. Равномерное заполнение этих диапазонов свидетельствует о том, что модель будет одинаково эффективна как для молодых пациентов, так и для лиц пожилого возраста.
2. Матрица корреляции признаков. Данный инструмент визуализации использовался для выявления коллинеарности — избыточной зависимости между факторами. Высокая корреляция между признаками может негативно сказаться на устойчивости аналитической модели. Визуальный анализ подтвердил, что выбранные параметры обладают достаточной независимостью, дополняя друг друга в комплексной оценке риска.

3. Диаграммы размаха или «ящики с усами» для числовых метрик. Применение этого метода позволило визуально подтвердить отсутствие аномальных выбросов после этапа очистки. Компактное расположение данных внутри межквартильного размаха свидетельствует о высокой однородности выборки.

Завершая оценку репрезентативности, можно констатировать, что сформированный массив данных является качественным фундаментом для последующего моделирования. Все критические параметры — от гендерного распределения до специфических генетических триггеров — представлены в объемах, достаточных для корректного обобщения диагностических паттернов.

Таким образом, на текущем этапе была проведена комплексная подготовка информационной базы проекта, включающая все ключевые процедуры: от первичной очистки данных и их нормализации до глубокой статистической оценки качества. Эта оценка осуществлялась через анализ сбалансированности классов и графический анализ распределений, что позволило выявить и устранить потенциальные искажения в наборе данных. Успешное выполнение этих последовательных шагов обеспечивает переход от работы с «сырой», необработанной информацией к этапу проектирования непосредственной архитектуры системы. Наличие качественного, тщательно очищенного и репрезентативного набора данных теперь предопределяет возможность уверенного перехода к следующему разделу работы. В нем будут подробно описаны этапы разработки проекта аналитического сервиса, включая определение структурных модулей системы, логику взаимодействия пользователя с интерфейсом и механизмы формирования итогового прогноза на основе уже проверенных и подготовленных данных.

## **2.2 Описание этапов разработки проекта системы**

### **2.2.1 Проектирование архитектуры решения**

Переход от этапа подготовки и статистического анализа данных к непосредственной реализации программного продукта требует детального описания структуры будущей системы. Архитектура аналитического сервиса является своего рода фундаментом, определяющим не только логику взаимодействия отдельных компонентов, но и обеспечивающим масштабируемость, надежность и удобство эксплуатации инструмента в реальных клинических условиях. Учитывая специфику работы врача в первичном звене здравоохранения, где приоритетными являются скорость отклика и интуитивная понятность интерфейса, в качестве архитектурного паттерна была выбрана монолитная модульная архитектура для desktop-приложения.

Выбор монолитной модульной архитектуры для разрабатываемой системы обусловлен, прежде всего, необходимостью создания полностью автономного и самодостаточного рабочего места специалиста. Такая реализация позволяет программному обеспечению бесперебойно функционировать без обязательного постоянного подключения к удаленным высокоскоростным облачным серверам, что является критически важным фактором для работы локальных медицинских кабинетов в условиях нестабильного сетевого соединения. В то же время, использование именно модульного подхода в рамках монолита дает возможность четко разграничить зоны ответственности между пользовательским интерфейсом, внутренней логикой обработки поступающих данных и вычислительным аналитическим ядром, что значительно упрощает процессы отладки кода и последующей функциональной модернизации системы. Подробная архитектурная схема

предлагаемого решения, включающая в себя пять ключевых функциональных слоев и описывающая связи между ними, представлена ниже на рисунке 2.1.




Рисунок 2.1 — Схема архитектуры системы

UI-слой или Пользовательский интерфейс. Визуальная оболочка спроектирована таким образом, чтобы быть интуитивно понятным новому пользователю.

Модуль загрузки данных. Одной из ключевых задач при проектировании была реализация гибкости источников информации. Разрабатываемый сервис поддерживает три сценария получения данных:

- Загрузка с локального диска файла CSV: позволяет врачу импортировать уже накопленные таблицы с данными пациентов;
- SQL-взаимодействие: обеспечивает возможность прямого подключения к локальным или сетевым базам данных медицинских организаций;
- Веб-импорт: модуль способен обращаться к внешним ресурсам или специализированным сайтам для получения актуальных

статистических выборок, что важно для дообучения модели на новых данных.

Модуль подготовки данных. Данный компонент является «внутренним фильтром» системы. Он наследует логику, описанную ранее в подразделе 2.1, автоматически проводя очистку, проверку типов и масштабирование признаков в режиме реального времени.

Аналитическое ядро. Это центральный элемент системы, отвечающий за интеллектуальную обработку информации. Модуль включает в себя механизмы загрузки предварительно обученной модели машинного обучения и алгоритмы проведения классификации. На основе входного вектора признаков датасета ядро вычисляет вероятность отнесения пациента к группе имеющих рак лёгких или не имеющих. Гибкость ядра позволяет как использовать статичную замороженную модель, так и проводить периодическое переобучение при накоплении критической массы новых клинических случаев.

Модуль презентации данных. Функция данного модуля заключается в интерпретации «сухих» цифр, полученных от аналитического ядра или представленных в датасете, в понятный для человека вид. Система не просто выдает текстовый вердикт, но и строит динамические графики и диаграммы. Это позволяет врачу не только увидеть итоговый риск, но и визуально оценить. Также это даёт возможность врачу лично изучить данные в более понятном для человека виде.

Информационный модуль. Учитывая роль сервиса как системы поддержки принятия решений, в архитектуру интегрирован справочный блок. Это цифровая библиотека, предоставляющая врачу доступ к медицинским рекомендациям, описаниям симптоматики и актуальным научным статьям. Модуль работает как контекстный помощник: при выявлении высокого риска система может автоматически предложить врачу ознакомиться с протоколами дальнейшей диагностики.

Проектирование архитектуры решения позволило структурировать функциональные требования к сервису и определить механизмы взаимодействия модулей — от момента поступления сырых данных до вывода графической интерпретации рисков. Выбранная монолитная модульная структура обеспечивает баланс между производительностью и простотой сопровождения.

Однако для того, чтобы описанные архитектурные элементы могли эффективно выполнять свои функции, необходимо строго определить формат данных, которыми они обмениваются, и математический фундамент, на котором будет строиться процесс прогнозирования. Четкое понимание структуры данных, сформированное в предыдущих параграфах, позволяет перейти к детальному описанию модели данных и математического аппарата, которые лежат в основе вычислительной логики системы.

### **2.2.2 Описание математического аппарата реализуемого решения**

Следующим важным этапом перед переходом к непосредственной реализации аналитического сервиса будет формализации используемых алгоритмов и определения математических принципов, на которых базируется процесс прогнозирования. Математический аппарат системы представляет собой совокупность методов машинного обучения, статистического анализа и функций предобработки, позволяющих преобразовать исходные клинико-анамнестические сведения в вероятностные оценки рисков.

Учитывая мультифакторную природу рака легких и необходимость выявления неявных зависимостей в данных, центральным элементом математического обеспечения системы является многослойная нейронная сеть или MLP, дополненная вспомогательными регрессионными и классификационными моделями для расчета сопутствующих параметров.

Формализация задачи обучения нейронной сети. Основная задача системы — поиск целевого параметра Final\_Prediction (наличие или отсутствие онкологического процесса). С математической точки зрения это задача бинарной классификации. Имеется обучающая выборка, состоящая из вектора входных признаков пациента и вектора истинных значений целевого признака.

Математическая модель нейронной сети представляется как сложная композиция функций, а её Формула представлена под номером 2.1.

$$F(x) = \sigma(W_L * ReLU(W_{L-1} * ReLU(... W_2 * ReLU(W_1 * x + b_1) + b_2) + ... + b_{L-1}) + b_L) \quad (2.1)$$

где  $W$  и  $b$  — матрицы весов и векторы смещений соответственно;

$ReLU(z) = \max(0, z)$  — функция активации на скрытых слоях, обеспечивающая нелинейность модели;

$\sigma(z)$  — сигмоидальная функция активации на выходном слое, преобразующая результат в вероятность от 0 до 1.

Для минимизации ошибки предсказания используется функция перекрестной энтропии или Binary Cross-Entropy. Формула данной функции представлена под номером 2.2.

$$L(y, \hat{y}) = - \frac{1}{n} \sum_{i=1}^n [y_i \ln(\hat{y}_i) + (1 - y_i) \ln(1 - \hat{y}_i)] \quad (2.2)$$

где  $n$  — всего предсказаний;

$y$  — истинный класс;

$\hat{y}$  — предсказанная вероятность.

Процесс обучения заключается в нахождении таких параметров  $W$  и  $b$ , которые минимизируют  $L$  с помощью метода стохастического градиентного

спуска с оптимизатором Adam, который эффективно адаптирует скорость обучения для каждого веса.

Математический аппарат вычисления сопутствующих параметров. Помимо основного прогноза, сервис реализует расчет дополнительных диагностических и прогностических показателей. Это требует применения различных математических подходов в зависимости от типа данных:

1. Mortality Risk (Риск смертности): данный параметр является непрерывной величиной в диапазоне  $[0, 1]$ . Для его предсказания используется нейросетевая регрессия с функцией потерь MSE, позволяющая оценить ожидаемую вероятность исхода на основе текущей стадии (Stage\_at\_Diagnosis) и гистологического типа (Cancer\_Type).
2. 5-Year Survival Probability (Вероятность 5-летней выживаемости): вычисляется также с использованием машинного обучения на основе остальных параметров.
3. Cancer Type (Тип рака) и Mutation Type (Тип мутации): для определения этих категориальных признаков используется много классовая классификация Softmax. Формула Softmax представлена под номером 2.3.

$$\text{Softmax}(z_j) = \frac{e^{z_j}}{\sum_{k=1}^K e^{z_k}} \quad (2.3)$$

где  $K$  — количество возможных типов мутаций или типов рака;

$z_j$  — входной вектор данных или логит;

$e^{z_j}$  — экспоненциальная функция.

Последним этапом станет метрическая оценка качества. Так как особое значение в математическом аппарате уделено метрикам оценки качества, а также тот факт, что вычисляется вероятность смертельного заболевания, то

цена ложноотрицательного результата критична, и как следствие, основное внимание будет уделяться параметру полноты, чья формула представлена в 2.4.

$$Recall = \frac{TP}{TP+FN} \quad (2.4)$$

где TP — верно предсказанные положительные объекты;

FN — ложноотрицательные предсказания, ошибка 2-го рода.

Также для закрепления и повышения точности будет использована F1 - мера, которая является наиболее сбалансированным методом оценки качества модели между точностью и полнотой. Формула представлена в 2.5.

$$F1 = \frac{2*TP}{2*TP+FP+FN} \quad (2.5)$$

где TP — верно предсказанные положительные объекты;

FN — ложноотрицательные предсказания, ошибка 2-го рода;

FP — ложноположительные предсказания, ошибка 1-го рода.

Описанный математический аппарат обеспечивает строгое обоснование логики работы аналитического сервиса, переводя клинические показатели пациента в плоскость численных вычислений. Использование нейронных сетей в сочетании с алгоритмами регрессионного анализа позволяет системе не только детектировать риск заболевания, но и предоставлять детализированный прогноз по выживаемости и молекулярному профилю опухоли. Выбранные математические функции и методы оптимизации подготавливают базу для реализации алгоритмической части программного продукта. Таким образом, от формальных математических зависимостей целесообразно перейти к описанию вычислительной схемы, которая определит последовательность выполнения данных операций в программной среде.

### 2.2.3 Разработки вычислительной схемы

Переход от концептуального описания архитектуры к непосредственной реализации аналитического сервиса требует детальной проработки вычислительной схемы. Вычислительная схема представляет собой технологический маршрут движения данных внутри системы: от момента их первичного ввода до генерации финальных медицинских рекомендаций. В рамках данного подраздела описывается логическая последовательность операций, выполняемых программными модулями, и их взаимодействие с математическим ядром системы.

Спроектированная схема функционирования сервиса включает в себя пять последовательных этапов, которые обеспечивают трансформацию «сырых» клинических признаков в интерпретируемый прогноз.

1. Ввод и первичная агрегация данных. Начальным этапом работы вычислительной схемы является точка входа данных. Учитывая описанную ранее архитектуру, система поддерживает пакетную обработку данных из внешних источников, таких как CSV-файлы, SQL-базы или запрос к интернет-ресурсу. На этом этапе происходит формирование первичного вектора признаков клинических показателей из датасета «Lung Cancer Risk & Prediction Dataset».
2. Подготовка и трансформация данных. Этот этап является критическим для обеспечения точности вычислений. Поскольку аналитическое ядро оперирует математическими алгоритмами, все входные данные должны быть стандартизированы. Вычислительная логика на данном этапе выполняет операции, ранее описанные в главе «Описание модели данных».
3. Аналитическая обработка и обучение модели. Сердцем вычислительной схемы является аналитическое ядро. Работа схемы

здесь разделяется на два режима:

- Режим обучения: система использует накопленный датасет для настройки внутренних весов классификатора. На основе математического аппарата, описанного в предыдущей главе, модель ищет скрытые закономерности между факторами риска и целевой переменной «Final\_Prediction»;
- режим прогнозирования: подготовленный на предыдущем этапе вектор данных пациента поступает на вход обученной модели. Вычислительная схема выполняет расчет вероятности наличия риска развития рака легких.

4. Вывод результатов и визуализация. После завершения математических расчетов данные передаются в модуль презентации. Вычислительная схема выдаёт численный результат развития рака. Параллельно, при наличии рака, запускаются процессы вычисления дополнительной информации, такой как тип рака и его мутация. Также по окончании процесса врачу предоставляется сгенерированные графики для более удобного анализа.
5. Генерация клинических рекомендаций. Заключительным этапом вычислительного цикла является предоставление прикладных советов для врача. На основе проведённого анализа программа предоставляет справочную и рекомендательную информацию по данному случаю.

Разработка вычислительной схемы позволила систематизировать процесс обработки медицинской информации, превратив теоретические математические выкладки в четкий алгоритм работы программных модулей. Описанный маршрут данных обеспечивает бесшовную интеграцию этапов подготовки, анализа и интерпретации результатов. Четкая структуризация

вычислительной логики от ввода данных до выдачи конкретных рекомендаций по обследованию пациента закладывает надежный технологический фундамент для реализации сервиса.

Описанная последовательность операций и функциональные требования к обработке данных определяют выбор конкретных технологических решений. Таким образом, логическим продолжением работы является переход к подбору инструментария, который позволит наиболее эффективно реализовать спроектированную схему на практике, что будет рассмотрено в следующем подразделе.

## **2.3 Обоснование выбора инструментальных средств разработки системы**

### **2.3.1 Сравнительный анализ и критерии выбора программных инструментов**

Важным этапом проектирования аналитического сервиса прогнозирования заболеваемости раком легких является обоснование выбора технологического стека. Учитывая специфику медицинской предметной области, программный инструментарий должен обеспечивать высокую точность вычислений, быстродействие при обработке данных и интуитивно понятную визуализацию для конечного пользователя — врача. В данном подразделе проводится сопоставление технологий, необходимых для реализации всех функциональных модулей системы, спроектированных в предыдущих главах.

Основой разработки был выбран язык программирования Python. Его выбор обусловлен наличием развитой экосистемы библиотек для

интеллектуального анализа данных и машинного обучения. В сравнении с такими языками, как C++ или Java, Python позволяет быстрее реализовывать сложные математические алгоритмы и гибко настраивать аналитическое ядро системы.

Для создания графического интерфейса пользователя (GUI) рассматривалось несколько библиотек: PyQt, PySide и Tkinter. Сравнительный анализ представлен в таблице 2.3.1.1.

*Таблица 2.3.1.1 — Сравнительный анализ библиотек для разработки GUI*

| Критерий выбора          | Tkinter                         | PyQt / PySide                               |
|--------------------------|---------------------------------|---------------------------------------------|
| Сложность освоения       | Низкая (стандартная библиотека) | Высокая (требуется изучения Qt)             |
| Вес итогового приложения | Минимальный                     | Значительный из-за тяжелых зависимостей     |
| Лицензирование           | Свободное (Python License)      | Коммерческое / GPL (ограничения)            |
| Скорость разработки      | Высокая для простых интерфейсов | Средняя (требуется предварительной верстки) |

Для реализации проектируемого сервиса была выбрана библиотека Tkinter. Она входит в стандартный дистрибутив Python, что обеспечивает легковесность приложения и отсутствие проблем с лицензированием в медицинских учреждениях. Поскольку интерфейс сервиса ориентирован на быстрый ввод данных и вывод графиков, возможностей Tkinter достаточно для реализации всех элементов UI-слоя.

Вторым критическим компонентом является модуль работы с данными. Учитывая описанную в подразделе 2.2.1 архитектуру, система должна поддерживать три типа источников. Для их реализации выбраны следующие инструменты:

1. Библиотека Pandas: основной инструмент для работы со структурированными данными, позволяющий загрузку CSV-файлов, фильтрацию, предобработку. Предоставляет инструменты для эффективной манипуляции признаковым пространством

датасета «Lung Cancer Risk & Prediction Dataset».

2. Библиотека `mysql-connector-python`: необходим для организации взаимодействия с базами данных MySQL. Это обеспечивает интеграцию сервиса в локальную инфраструктуру медицинских организаций.
3. Библиотека `KaggleApi`: выбрана для реализации веб-импорта, в данном случае с сайта `KaggleApi`, позволяя приложению безопасно загружать актуальные статистические выборки с внешнего аналитического ресурса.

Для реализации математического аппарата, включая многослойную нейронную сеть MLP и алгоритмы классификации, выбрана библиотека `Scikit-learn`. В отличие от тяжеловесных фреймворков вроде TensorFlow или PyTorch, `Scikit-learn` предоставляет оптимальные инструменты для обучения моделей на классических табличных данных, обеспечивая при этом высокую скорость работы на стандартном офисном оборудовании терапевта. Также она включает в себя функции для расчета метрик Recall и F1-score, которые признаны ключевыми в данной работе.

Модуль презентации данных и визуализации будет реализован с помощью библиотеки `Matplotlib`. Этот инструмент позволяют строить корреляционные матрицы, гистограммы распределения рисков и «ящики с усами», обеспечивая наглядность, необходимую для снижения когнитивной нагрузки на врача.

Таким образом, для разработки системы был сформирован следующий технологический стек:

- Язык: Python;
- Интерфейс: Tkinter;
- Обработка и моделирование: Pandas, Scikit-learn, NumPy;
- Хранение и доступ: `mysql-connector-python` (MySQL), `KaggleApi`

(Web) и Pandas (CSV);

- Визуализация: Matplotlib.

Выбранный набор инструментов полностью соответствует требованиям к легкости, автономности и аналитической мощности сервиса. Это позволяет обеспечить баланс между сложностью математических вычислений и доступностью приложения для первичного звена здравоохранения.

Сформированные критерии выбора и утвержденный программный стек создают фундамент для детального описания технической реализации проекта. Определив программную среду, мы можем перейти к конкретизации технических требований к аппаратной части и инфраструктуре, в которой будет развернут сервис, что и станет предметом рассмотрения в следующем разделе.

### **2.3.2 Описание выбранной среды разработки и требований к инфраструктуре**

Определив архитектурные особенности и выбрав ключевые программные инструменты, нам следует конкретизировать требования к техническому обеспечению, в рамках которого будет производиться разработка и последующая эксплуатация аналитического сервиса. Для обеспечения стабильной работы моделей машинного обучения и графического интерфейса требуется сбалансированная программно-аппаратная среда.

В качестве основной среды разработки IDE была выбрана PyCharm от компании JetBrains. Выбор данной среды обусловлен её профессиональным функционалом, который значительно упрощает процесс написания и отладки кода для аналитических систем. В таблице 2.3.2.1 представлено сравнение PyCharm с популярным аналогом VS Code для обоснования выбора в рамках данной ВКР.

Таблица 2.3.2.1 — Сравнительный анализ сред разработки IDE

| Критерий           | PyCharm (Community Edition)                                | Visual Studio Code (VS Code)             |
|--------------------|------------------------------------------------------------|------------------------------------------|
| Специализация      | Полностью ориентирована на Python                          | Универсальный редактор (через плагины)   |
| Анализ данных      | Встроенная поддержка Scientific mode и отладки датафреймов | Требуется установка множества расширений |
| Удобство дебаггера | Высокое (графическая визуализация переменных в памяти)     | Среднее (текстовый вывод)                |
| Опыт разработчика  | Имеющийся опыт работы в среде, что ускоряет разработку     | Требуется времени на настройку окружения |

Для реализации проекта и его функционирования на рабочем месте врача установлены следующие системные требования:

1. Программные требования:
  - Операционная система: Windows 10 или Windows 11 (64-бит). Выбор обусловлен доминированием данной ОС в медицинских информационных инфраструктурах первичного звена.
  - Интерпретатор: Python версии 3.9 и выше. Данная версия обеспечивает стабильную поддержку Scikit-learn и Pandas.
  - Пакетный менеджер: pip, используемый для управления зависимостями и установки необходимых библиотек.
2. Аппаратные требования: в отличие от систем глубокого обучения, спроектированный сервис использует классические алгоритмы машинного обучения и нейронные сети типа MLP, что позволяет снизить требования к «железу». Также это повысит комфорт работы врача-терапевта за счёт быстрого отклика интерфейса. На основе требований к работе с нейронными сетями, графиками была определена следующая минимальная конфигурация:
  - Процессор: Intel Core i3 (или аналогичный процессор AMD Ryzen 3) с тактовой частотой от 2.5 ГГц. Этого достаточно для проведения расчетов на CPU, но желательно использовать

более мощные для ускорения вычислений.

- Оперативная память (RAM): не менее 8 ГБ. Данный объем необходим для удержания в памяти датасета при обучении ансамблевых моделей и предотвращения задержек при визуализации «ящиков с усами» или корреляционных матриц.
- Видеокарта: наличие дискретного графического ускорителя необязательно, так как библиотека Scikit-learn проводит вычисления исключительно на центральном процессоре.
- Свободное место на диске: не менее 500 МБ для установки Python и всех зависимых модулей.

3. Информационная безопасность и конфиденциальность данных: Особое внимание при выборе технической реализации уделено защите медицинских данных. Исполнение кода спроектировано локально. Это означает, что все аналитические операции, предобработка факторов риска и само прогнозирование происходят на компьютере врача без передачи персональных сведений пациента на внешние облачные серверы. Внешние запросы осуществляются только модулем веб-импорта для загрузки обновленных статистических выборок, что гарантирует автономность и безопасность сервиса в контуре медицинского учреждения.

Анализ предметной области и существующих ИТ-решений в онкологии подтвердил необходимость разработки сервиса поддержки принятия решений на базе Python и Scikit-learn. В ходе проектирования была сформирована модульная архитектура, обосновано применение нейросетей MLP и выбран технологический стек. Установленные требования создают основу для перехода к практическому этапу. В следующем, «Технологическом разделе», будет описана программная реализация модулей системы, алгоритмов обучения модели и пользовательского интерфейса.

## ЗАКЛЮЧЕНИЕ

Существующий дефицит доступных инструментов для оперативной многофакторной оценки рисков онкологических заболеваний во многом связан с тем, что рыночные аналоги фокусируются на узкоспециализированной диагностике КТ-снимков или выполняют функции пассивного сопровождения. В таких системах нередко игнорируются важные переменные: образ жизни, экологические факторы и генетическая предрасположенность пациента. Для минимизации «информационной слепоты» врача и повышения точности первичного скрининга разработан проект легковесного аналитического сервиса, способного интегрироваться в текущие рабочие процессы.

В основе системы лежит комплексная информационная модель на базе набора данных «Lung Cancer Risk & Prediction Dataset». После предобработки и очистки данных спроектирована модульная архитектура с аналитическим ядром и понятным модулем визуализации результатов. В качестве математического аппарата обосновано применение многослойной нейронной сети и алгоритмов классификации с приоритетом максимизации полноты для снижения пропуска патологий.

Технологический стек на Python с использованием Scikit-learn и Tkinter обеспечивает автономность и высокую производительность решения на стандартном офисном оборудовании медицинских организаций. Полученные результаты подтверждают реализуемость и практическую значимость проекта. Сформированная база достаточна для перехода к программной реализации сервиса и полномасштабной экспериментальной оценке точности предиктивных моделей.

# СПИСОК ИСПОЛЬЗУЕМЫХ ИСТОЧНИКОВ

## ИССЛЕДОВАТЕЛЬСКИЙ РАЗДЕЛ

- 1.1. Б.А. Кобринский. Единое информационное пространство: E-health и M- health // Телемедицина. –2016. – №4. – С. 57–66
- 1.2. Iot.ru [электронный ресурс] <https://iot.ru/wiki/e-health>
- 1.3. Медицинская информатика: учеб. для студ. учреждений высш. проф. образования / Б.А.Кобринский, Т.В.Зарубина. — 4-е изд., перераб и доп. — М.: Издательский центр «Академия», 2013. — 192 с.
- 1.4. Шифрин М.А. Медицинская информатика – смена парадигмы в эпоху мгновенных коммуникаций // Научный сервис в сети Интернет: труды XVIII Всероссийской научной конференции (19-24 сентября 2016 г., г. Новороссийск). — М.: ИПМ им. М.В.Келдыша, 2016. — С. 333-338.
- 1.5. Рак легкого. Под ред. К. К. Лактионова и В. В. Бредера — М.: «ГРАНАТ», 2020. — 151 с.
- 1.6. ФГБУ «НМИЦ радиологии» Минздрава России [электронный ресурс] <https://new.nmicr.ru/patientam/oncology/verhnie-dyhatelnye-puti/rak-legkogo/>
- 1.7. Rustore [электронный ресурс] <https://www.rustore.ru/catalog/app/ru.medsolutions>
- 1.8. Uzmedlib [электронный ресурс] <https://uzmedlib.uz/uptodate>
- 1.9. РОСТГМУ [электронный ресурс] [https://rostgmu.ru/archives/1966#:~:text=UpToDate%20\(www.uptodate.com,%D0%BA%D0%BE%D1%82%D0%BE%D1%80%D1%8B%D0%B9%20%D0%BF%D1%80%D0%BE%D1%85%D0%BE%D0%B4%D0%B8%D1%82%20%D0%BD%D0%B5%D1%81%D0%BA%D0](https://rostgmu.ru/archives/1966#:~:text=UpToDate%20(www.uptodate.com,%D0%BA%D0%BE%D1%82%D0%BE%D1%80%D1%8B%D0%B9%20%D0%BF%D1%80%D0%BE%D1%85%D0%BE%D0%B4%D0%B8%D1%82%20%D0%BD%D0%B5%D1%81%D0%BA%D0)

%BE%D0%BB%D1%8C%D0%BA%D0%BE%20%D1%83%D1%80  
%D0%BE%D0%B2%D0%BD%D0%B5%D0%B9%20%D1%80%D0  
%B5%D1%86%D0%B5%D0%BD%D0%B7%D0%B8%D1%80%D0  
%BE%D0%B2%D0%B0%D0%BD%D0%B8%D1%8F.

- 1.10.Medscape [электронный ресурс] <https://www.medscape.com/>
- 1.11.Webcatalog [электронный ресурс] <https://webcatalog.io/ru/apps/medscape>
- 1.12.App Store [электронный ресурс] <https://apps.apple.com/ru/app/mdcalc-medical-calculator/id1001640662>
- 1.13.National Center for Biotechnology Information [электронный ресурс] <https://pmc.ncbi.nlm.nih.gov/articles/PMC9762565/#:~:text=The%20website%20estimates%20that%20%E2%80%9Cas,for%20inclusion%20of%20new%20calculator>
- 1.14.QxMD [электронный ресурс] <https://qxmd.com/calculate/>
- 1.15.Pedi-stat [электронный ресурс] <https://www.pedi-stat.com/>
- 1.16.IBM [электронный ресурс] <https://newsroom.ibm.com/2021-11-30-IBM-Watson-Health-Introduces-New-Opportunities-for-Imaging-AI-Adoption#:~:text=About%20IBM%20Watson%20Health,com/watson%2Dhealth>
- 1.17.Zdrav.expert [электронный ресурс] [https://zdrav.expert/index.php/%D0%9F%D1%80%D0%BE%D0%B4%D1%83%D0%BA%D1%82:IBM\\_Watson\\_Health](https://zdrav.expert/index.php/%D0%9F%D1%80%D0%BE%D0%B4%D1%83%D0%BA%D1%82:IBM_Watson_Health)
- 1.18.Doctolib [электронный ресурс] <https://www.doctolib.de/>
- 1.19.ЕМИАС [электронный ресурс] <https://emias.info/>
- 1.20.МЦПМК [электронный ресурс] <https://medical-training.ru/news/press-reliz/chto-takoe-emias-i-kak-s-ney-rabotat/>
- 1.21.Ada [электронный ресурс] <https://ada.com/>
- 1.22.Sber Med AI [электронный ресурс] <https://sbermed.ai/>

- 1.23. Ftizis bio med [электронный ресурс] <https://ftizisbiomed.ru/>
- 1.24. Искусственный медицинский интеллект «ФтизисБиомед»: программа автоматизированного анализа цифровых рентгенограмм органов грудной клетки/флюорограмм / Ю. Т. Гогоберидзе, В. И. Клас-сен, М. Я. Натензон [и др.]. – 2023. – Т. 15, № 4. – С. 5–21.
- 1.25. ONCOTODAY [электронный ресурс] <https://oncoday.pro/>
- 1.26. IBM [электронный ресурс] [https://www.ibm.com/mysupport/s/topic/0TO500000002PWlGAM/watson-for-oncology?language=en\\_US](https://www.ibm.com/mysupport/s/topic/0TO500000002PWlGAM/watson-for-oncology?language=en_US)
- 1.27. Google Health [электронный ресурс] <https://health.google/>
- 1.28. Цельс [электронный ресурс] <https://celsus.ai/>
- 1.29. Microsoft [электронный ресурс] <https://news.microsoft.com/ru-ru/features/botkinai/>
- 1.30. Evercare [электронный ресурс] [https://evercare.ru/sites/default/files/2020-05/%D0%A1%D0%BE%D1%80%D0%BE%D0%BA%D0%B8%D0%BD\\_Botkin.AI%20%D0%A2%D0%B5%D0%BB%D0%B5%D0%BC%D0%B5%D0%B4%D1%84%D0%BE%D1%80%D1%83%D0%BC.pdf](https://evercare.ru/sites/default/files/2020-05/%D0%A1%D0%BE%D1%80%D0%BE%D0%BA%D0%B8%D0%BD_Botkin.AI%20%D0%A2%D0%B5%D0%BB%D0%B5%D0%BC%D0%B5%D0%B4%D1%84%D0%BE%D1%80%D1%83%D0%BC.pdf)

- 2.1. Kaggle [электронный ресурс] <https://www.kaggle.com/datasets/ankushpanday1/lung-cancer-risk-and-prediction-dataset?resource=download>
- 2.2. Предварительная обработка данных для машинного обучения / А.А. Акимов, Д.Р. Валитов, А.И. Кубряк – 2022 – №2 – С. 26–31.
- 2.3. Habr [электронный ресурс] <https://habr.com/ru/companies/skillfactory/articles/848858/>

- 2.4. Loginom [электронный ресурс] <https://loginom.ru/blog/data-quality-criteria>
- 2.5. Loginom [электронный ресурс] <https://loginom.ru/blog/representativity>
- 2.6. Фундаментальный подход к программной архитектуре: паттерны, свойства, проверенные методы. — СПб.: Питер, 2023. — 448 с.
- 2.7. Systems.education [электронный ресурс] [https://systems.education/software\\_styles\\_and\\_patterns\\_with\\_cheatsheet#showmore](https://systems.education/software_styles_and_patterns_with_cheatsheet#showmore)
- 2.8. Глубокое обучение / пер. с англ. А. А. Слинкина. — 2-е изд., испр. — М.: ДМК Пресс, 2018. — 652 с
- 2.9. Глубокое обучение на Python. 2-е межд. издание. — СПб.: Питер, 2023. — 576 с
- 2.10. Habr [электронный ресурс] <https://habr.com/ru/articles/922454/>
- 2.11. Habr [электронный ресурс] <https://habr.com/ru/articles/803397/>
- 2.12. Habr [электронный ресурс] <https://habr.com/ru/articles/820411/>
- 2.13. Medium [электронный ресурс] <https://medium.com/@piyushkashyap045/understanding-precision-recall-and-f1-score-metrics-ea219b908093>
- 2.14. Программирование на Python, том I, 4-е издание. — Пер. с англ. — СПб.: Символ-Плюс, 2011. — 992 с.
- 2.15. Python [электронный ресурс] <https://docs.python.org/3/>
- 2.16. Qt [электронный ресурс] <https://doc.qt.io/qtforpython-6/>
- 2.17. Python [электронный ресурс] <https://docs.python.org/3/library/tkinter.html>
- 2.18. Pandas [электронный ресурс] <https://pandas.pydata.org/>
- 2.19. PyPI [электронный ресурс] <https://pypi.org/project/mysql-connector-python/>
- 2.20. Kaggle [электронный ресурс] <https://www.kaggle.com/docs/api>
- 2.21. PyPI [электронный ресурс] <https://pypi.org/project/scikit-learn/>

- 2.22. PyPI [электронный ресурс] <https://pypi.org/project/tensorflow/>
- 2.23. PyPI [электронный ресурс] <https://pypi.org/project/torch/>
- 2.24. JetBrains [электронный ресурс] <https://www.jetbrains.com/pycharm/>
- 2.25. Visual Studio Code [электронный ресурс] <https://code.visualstudio.com/>

## **ПРИЛОЖЕНИЕ**