

Слайд 1 Титульный лист

Уважаемые Председатель и члены государственной экзаменационной комиссии. Вашему вниманию представляется Выпускная квалификационная работа Соколова Александра Владимировича, на тему: «Разработка аналитического сервиса прогнозирования заболеваемости раком лёгких»

Научный руководитель: Аристов Анатолий Игоревич.

Слайд 2 Актуальность и цель исследования

Актуальность работы обусловлена высокой значимостью раннего выявления рака легких и ростом объема медицинских данных.

Информационные технологии и методы машинного обучения позволяют повысить оперативность и обоснованность первичной диагностики.

{Сделать акцент!} Цель работы — разработка и реализация приложения для быстрого раннего диагностирования возможного рака легких на основе статистической информации.

Слайд 3 Объект, предмет и задачи исследования

Объект исследования — программный аналитический сервис поддержки принятия врачебных решений.

Предмет исследования — методы и алгоритмы машинного обучения для оценки риска возникновения рака легких.

Задачи исследования:

1. исследовать предметную область.
2. проанализировать существующие решения.
3. сформировать требования к системе.
4. разработать архитектуру и реализовать приложение.
5. обучить и протестировать модели.
6. оценить эффективность разработанного решения.

Слайд 4 Анализ предметной области

Предметная область находится на стыке медицины, математической статистики и информационных технологий.

Основные проблемы:

1. позднее выявление заболевания;
2. большой объем разнородных данных;
3. высокая когнитивная нагрузка на врача;
4. дефицит доступных аналитических сервисов для первичного звена.

Слайд 5 Обзор существующих решений

Смотрите на таблицу.

Слайд 6 Постановка задачи на ... (как в задании на ВКР)

Необходимо разработать настольный сервис, который:

1. работает со структурированными клинико-анамнестическими данными;
2. выполняет предобработку и анализ данных;
3. поддерживает визуализацию данных;
4. оценивает вероятность наличия рака легких;
5. содержит справочный модуль для врача.

Основные требования:

1. понятный интерфейс;
2. автономная работа;
3. поддержка импорта данных из CSV, SQL и веб-источников;
4. высокая полнота выявления положительных случаев.

Слайд 7 Описание модели данных

Ниже приведен перечень параметров (столбцов) используемого набора данных с кратким описанием каждого показателя (25 колонок):

- Country — страна проживания пациента для учета региональной

специфики и качества среды;

- Age — возраст пациента (в диапазоне от 30 до 90 лет), являющийся одним из ключевых факторов риска;
- Gender — пол пациента (мужской или женский);
- Smoking_Status — текущий статус курения (курильщик, некурящий, бывший курильщик);
- Second_Hand_Smoke — наличие фактора пассивного курения в окружении пациента;
- Air_Pollution_Exposure — уровень воздействия загрязненного атмосферного воздуха (низкий, средний, высокий);
- Occupation_Exposure — наличие вредных производственных факторов на месте работы;
- Rural_or_Urban — тип местности проживания (сельская или городская среда);
- Socioeconomic_Status — социально-экономический статус пациента, влияющий на образ жизни;
- Healthcare_Access — уровень доступности медицинской помощи (хороший, ограниченный, плохой). Оценивается на основе сложности получения медицинской помощи и её качестве;
- Insurance_Coverage — наличие медицинской страховки у пациента;
- Screening_Availability — доступность программ диспансеризации и профилактических осмотров;
- Stage_at_Diagnosis — стадия заболевания, зафиксированная на момент постановки диагноза (от I до IV);
- Cancer_Type — гистологический тип рака (мелкоклеточный или немелкоклеточный);
- Mutation_Type — выявленный тип генетической мутации (EGFR, ALK, KRAS или их отсутствие);
- Treatment_Access — возможность получения необходимого лечения

в полном или частичном объеме;

- `Clinical_Trial_Access` — информация об участии пациента в клинических испытаниях новых препаратов;
- `Language_Barrier` — наличие языкового барьера, затрудняющего коммуникацию с врачом;
- `Mortality_Risk` — расчетная вероятность летального исхода в диапазоне от 0.0 до 1.0;
- `5_Year_Survival_Probability` — статистическая вероятность выживаемости в течение пяти лет;
- `Delay_in_Diagnosis` — зафиксированные задержки в процессе постановки диагноза;
- `Family_History` — наличие случаев онкологических заболеваний в семейном анамнезе;
- `Indoor_Smoke_Exposure` — воздействие дыма внутри жилых или рабочих помещений;
- `Tobacco_Marketing_Exposure` — степень подверженности влиянию рекламы табачной продукции;
- `Final_Prediction` — целевой признак, определяющий наличие или отсутствие рака легких в финальном прогнозе.

Слайд 8 Архитектура и этапы разработки системы

Разработана монолитная модульная архитектура desktop-приложения (позволяет добиться автономности и самодостаточности рабочего места специалиста, а также позволяет разбить приложения на элементы, что повышает удобство работы с кодом в будущем).

Ключевые модули системы:

1. пользовательский интерфейс;
2. модуль загрузки данных;
3. модуль подготовки данных;
4. аналитическое ядро;

5. модуль визуализации;
 6. информационно-справочный модуль.
- Дать краткое пояснение по каждому модулю

Слайд 9 Обоснование выбора инструментальных средств

Для реализации использованы:

1. Python;
2. Pandas и NumPy для обработки данных;
3. Scikit-learn для построения моделей;
4. Matplotlib для визуализации;
5. MySQL Connector и Kaggle API для загрузки данных;
6. Tkinter для графического интерфейса.

Питон выбран за счёт, развитой экосистем библиотек, что значительно ускоряет процесс реализации сложных алгоритмов.

Pandas и NumPy являются библиотеками, которые позволяют более тонко и удобно работать с многомерными данными. Также Pandas позволяет загружать локальные файлы формата CSV.

Scikit-learn удобна тем, что она предоставляет оптимальные инструменты для обучения моделей на классических табличных данных, обеспечивая при этом высокую скорость работы на стандартном офисном оборудовании.

Matplotlib была выбрана за счёт удобства и простоты построения разнообразных диаграмм.

MySQL Connector и Kaggle API являются специальными библиотеки для получения доступа к базе данных MySQL и веб-ресурсу Kaggle соответственно.

Также на следующем слайде представлена таблица сравнения библиотек для создания интерфейса

Слайд 10

Сравним библиотеки графического интерфейса.

Смотри таблицу

Выбрана библиотека Tkinter так как, она входит в стандартный дистрибутив Python, что обеспечивает легковесность приложения и отсутствие проблем с лицензированием в медицинских учреждениях.

Слайд 11 Проектирование системы

Далее для удобства и понятности будут представлены различные диаграммы, описывающие разрабатываемое приложение

Слайды 11-13.

Непосредственно код приложения можно увидеть в Приложении А к ВКР.

Слайд 14 Демонстрация работоспособности решения

Далее кратко пробежимся по демонстрации работы приложения

Слайды 14-21.

Слайд 22 Организация методики тестирования

В качестве методики тестирования была выбрана экспертное тестирование.

Тестироваться будет:

1. Стабильность работы.
2. Скорость работы.
3. Некорректные вводные.
4. Тестирование созданных моделей.

Для удобства понимания тестирование будет представлено в виде таблиц

Тестирование системы авторизации

Тестирование системы регистрации (кратко)
Тестирование базового меню (кратко)
Тестирование загрузки с диска
Тестирование загрузки из базы данных
(при некоренных параметрах подключения программа не
запускается)
Тестирование загрузки с сайта
Тестирование визуализации гистограммы
(все гистограммы визуализированы)
Тестирование создание нейронных сетей на 81975 записях
Тестирование создание нейронных сетей на 171087 записях
Тестирование создание нейронных сетей на 306533 записях
Импорт и экспорт нейронных сетей
(успешно, работает по тому же принципу что и загрузка с
локального диска)
Справочник
(успешно, работает по тому же принципу что и загрузка с
локального диска)

Слайды 22-29

Слайд 30

Исходя из проведённых тестирований, можно сказать:

1. Во-первых, нейронные сети, особенно под номерами 4 и 5, требуют значительного времени на обучение, поэтому для повышения удобства работы программы желательно предварительно обучать модели на более мощном компьютере, а затем переносить готовые сети для последующего использования.
2. Во-вторых, нейронные сети для определения наличия рака и его типа показали достаточно хорошие результаты и при дальнейшем увеличении объёма данных могут достичь ещё более высокого качества.
3. В-третьих, нейронная сеть для определения мутации пока не имеет нужного уровня точности, поэтому стоит либо рассмотреть другую архитектуру модели, либо увеличить объём обучающих данных.

4. В-четвёртых, нейронные сети для расчёта вероятности смерти и вероятности выживания показали очень низкую информативность, что может означать слабую связь этих признаков с остальными данными либо необходимость применения другой модели для повышения точности.
5. Наконец, остальные элементы программы работают стабильно и без ошибок.

Слайд 31

В результате проведённой работы ВКР, был произведён анализ предметной области, рассмотрены существующие решения, а на их основе сформированы требования к разрабатываемому сервису.

На основе полученных требований было спроектирован и реализован аналитический сервис поддержки принятия врачебных решений для ранней диагностики рака легких.

После проведения его тестирования можно выделить следующие факты:

1. Основная цель достигнута.
2. Дополнительные цели достигнуты частично.

Разработанное приложение представляет собой завершённый программный продукт, готовый к тестовой эксплуатации. Оно снижает когнитивную нагрузку на врачей-терапевтов и пульмонологов, объективизирует выделение групп риска и повышает оперативность направления пациентов на углубленную диагностику, способствуя раннему выявлению онкологических процессов.